# 무릎 MRI 다중 소견 탐지에서의 약지도 라벨링과 소견별 상보성 기반 앙상블

Woomin Jeong

한밭대학교 컴퓨터공학과

**초록** 본 연구는 무릎 MRI 검사 단위로 12개 소견(전·내측 측부인대 파열, 내·외측 반월상연골 파열, 내측·외측·슬개대퇴 골관절염, 관절 삼출, 활막염, 베이커 낭종, 골좌상, 골절)을 동시에 판정하는 다중 레이블 분류 문제를 다룬다. 학습 검사 4,407건 가운데 전문가 정답이 있는 것은 58건뿐이며, 나머지에는 다국어 자유 서술 판독문만 주어진다. 이 조건에서 우리는 세 가지를 제안하고 검증한다. 첫째, 판독문과 대표 영상을 함께 해석하는 대규모 언어모델로 연한 라벨을 만들고, 라벨 출처를 소견별로 선택한다(전문가 정답 기준 평균 AUC 0.926 → 0.936). 둘째, 대회와 독립된 외부 코호트(OAI, 2,377 무릎)에서 모델 간 소견별 상보성을 측정하고, 이를 근거로 앙상블 가중치를 소견마다 다르게 둔다. 그 결과 균일 가중 대비 외부 코호트 AUC가 0.9451에서 0.9474로, 공개 시험 집합 AUC가 0.957에서 0.958로 향상되었다. 셋째, 해부학적 기준점으로 무릎 관절을 잘라 보는 관심영역 중심 학생 모델을 제안된 라벨로 학습한다. 동일 백본·동일 라벨에서 전체 시야 입력(0.913) 대비 전문가 정답 AUC가 0.941로 높았다. 최종 앙상블은 공개 시험 집합에서 AUC 0.959를 기록했다. 이와 함께 지식 증류가 단일 모델 성능을 높이는 대신 앙상블 기여를 줄이는 현상, 외부 데이터 혼합과 2차 증류의 실패를 분석한다.

핵심어: 무릎 MRI, 약지도 학습, 대규모 언어모델 라벨링, 다중 인스턴스 학습, 지식 증류, 앙상블 상보성, 관심영역 기반 학습

## 1. 서론

근골격계 MRI 판독 자동화는 소견 수가 많고 소견 사이에 해부학적 의존성이 있어 어려운 문제다. 또한 대규모 전문가 주석을 확보하기 어렵다. 실제 임상 데이터에는 판독문이 함께 저장되므로, 판독문에서 라벨을 추출하는 약지도 학습이 현실적인 대안으로 연구되어 왔다. 그러나 판독문은 언급하지 않은 소견에 대해 침묵하고 표현이 기관과 언어마다 달라, 추출된 라벨에 체계적인 잡음이 생긴다.

본 연구는 RSNA Knee Abnormality Detection 데이터(학습 4,407 검사, 전문가 정답 58 검사, 숨겨진 시험 1,322 검사)에서 다음 질문을 다룬다. (1) 판독문만 있는 검사에서 얼마나 정확한 연한 라벨을 만들 수 있는가. (2) 서로 다른 데이터·라벨로 학습된 여러 모델을 어떻게 결합해야 하는가. 특히 단일 성능이 낮은 모델도 앙상블에 기여할 수 있는가. (3) 입력 시야(field of view)는 소견별 성능에 어떤 영향을 주는가.

주요 기여는 다음과 같다.

- 판독문 단독 라벨과 영상+판독문 다중모달 라벨을 비교하고, 소견별 출처 선택이 라벨 품질을 높임을 보인다(3절).
- 독립 외부 코호트에서 모델 간 소견별 상보성을 정량화하고, 이에 기반한 소견별 가중 앙상블을 제안한다(5절).
- 지식 증류가 단일 모델 성능과 앙상블 기여 사이에서 상충 관계를 만든다는 것을 보인다. 또 같은 입력 표현 안에서는 앙상블 기여가 포화된다는 것도 보인다(6.3절).
- 입력 시야 가설을 좌우 정규화 대조 실험과 관심영역 학생 모델로 검증한다(6.4절).

## 2. 데이터와 평가 방법

### 2.1 데이터

각 검사는 시상면·관상면·축상면의 여러 시리즈(지방억제 여부 포함)로 이루어진 DICOM과 판독문을 포함한다. 판독문은 스페인어·네덜란드어·영어 등으로 작성되었고 서식이 표준화되어 있지 않다. 동일한 판독문을 공유하는 검사 그룹이 있어, 교차검증 분할은 판독문 그룹 단위로 수행했다. 평가 지표는 12개 소견별 ROC-AUC의 산술 평균이다.

### 2.2 평가 집합

세 평가 집합을 상호 보완적으로 사용했다(표 1). 전문가 정답 집합(이하 G58)은 규모가 작고 라벨 출처 선택에도 쓰였으므로 탐색적 지표로만 해석한다. 외부 코호트 평가는 Osteoarthritis Initiative(OAI)의 2,377 무릎에서 MOAKS 기반 전문가 판독으로 9개 소견을 평가한다. 대회 데이터와 독립되어 있으나 도메인 차이가 있다. 공개 시험 집합은 숨겨진 시험 데이터의 약 30%로, 표본 오차가 약 0.003이다. 본 보고서에서 채택한 결론은 원칙적으로 둘 이상의 평가 집합에서 같은 방향의 효과가 관찰된 경우로 한정한다.

| 평가 집합 | 규모 | 독립성 | 주요 한계 |
|---|---|---|---|
| G58 (전문가 정답) | 58 검사 | 모델 학습에서 제외 | 양성 9~35건, 라벨 선택에 재사용(낙관적 편향) |
| OAI 외부 코호트 | 2,377 무릎, 9개 소견 | 완전 독립 | 도메인 차이, 일부 모델은 원본 영상 부재로 평가 불가 |
| 공개 시험 집합 | 약 400 검사 | 완전 독립 | 표본 오차 약 0.003, 소수점 셋째 자리까지만 공개 |

**표 1.** 평가 집합의 특성.

## 3. 약지도 라벨 구축

### 3.1 판독문 기반 라벨

판독문에서 소견별 확률을 추출하는 독자(reader) 여러 개를 구성했다. 오픈 대규모 언어모델 6종의 평균(6R), Claude 텍스트 독자, Astra 텍스트 독자 등이다. 판독문이 소견을 언급하지 않은 칸(silent cell)은 음성으로 간주하지 않고, 학습 손실에서 제외하거나 교사 모델 예측으로 채웠다.

### 3.2 영상+판독문 다중모달 라벨

판독문의 침묵을 보완하기 위해, 시리즈별 대표 슬라이스 몽타주와 판독문을 함께 입력해 소견을 판정하는 다중모달 라벨을 생성했다(Claude 영상+판독문, Astra 영상+판독문). 이 방식은 판독문에 언급되지 않은 소견에도 영상 근거로 확률을 부여한다.

### 3.3 소견별 출처 선택

출처마다 상대적으로 강한 소견이 달랐다. 관절 삼출과 베이커 낭종은 영상 정보가 있는 다중모달 라벨이, 슬개대퇴 골관절염은 텍스트 라벨이 우수했다. 따라서 소견 $c$마다 G58 AUC 상위 두 출처의 평균을 학습 라벨로 사용했다.

| 라벨 출처 | G58 평균 AUC |
|---|---|
| Claude 텍스트 | 0.908 |
| 오픈 LLM 6종 평균 (6R) | 0.910 |
| Claude 영상+판독문 | 0.916 |
| Astra 영상+판독문 | 0.924 |
| 세 출처 평균 (6R, Astra 영상, Claude 영상) | 0.926 |
| **소견별 상위 두 출처 평균** | **0.936** |

**표 2.** 라벨 출처별 G58 성능. 마지막 행은 출처를 G58로 선택했으므로 낙관적으로 편향된 값이며, 이 편향은 6.4절에서 외부 코호트로 재검증한다.

## 4. 모델

### 4.1 2.5D 다중 인스턴스 모델(전체 시야)

검사를 평면과 지방억제 여부에 따른 슬롯으로 나누고, 슬롯당 최대 96 슬라이스를 384px로 정규화했다. 인접한 세 슬라이스를 하나의 인스턴스(창)로 보고 ConvNeXt 백본으로 특징을 추출한 뒤, 슬롯·위치 임베딩과 트랜스포머 한 층을 거쳐 소견별 주의 기반 다중 인스턴스 풀링으로 검사 단위 로짓을 얻는다. 학습 시에는 검사당 16개 인스턴스를 무작위로 뽑고, 추론 시에는 모든 유효 인스턴스(평균 약 94개)와 해부학적 좌우 반전 시험 시간 증강을 사용한다.

### 4.2 지식 증류

판독문 라벨 $y$와 공개된 CoAtNet 기반 교사 모델의 학습 데이터 예측 $t$를 섞은 목표 $\tilde{y} = 0.5y + 0.5t$로 학생을 학습했다. 라벨이 침묵하는 칸에는 $t$만 사용했다. 15 epoch 학습했으며, 가중치 지수 이동평균(0.999)을 평가에 사용했다.

### 4.3 교사 없는 공간 주의 모델

교사 모델과 다른 오차 구조를 얻기 위해, ConvNeXt-S에 소견별 공간 주의(인스턴스 내부 위치에 대한 소견별 질의)를 추가하고 교사 없이 약지도 라벨만으로 학습했다.

### 4.4 관심영역 중심 학생 모델

SKM-TEA 데이터로 학습된 공개 해부학 분할 모델로 무릎 관절의 기준점을 찾고, 주변 약 100mm 영역과 전체 시야를 함께 288px로 잘라 입력하는 공개 학습 파이프라인을 채택했다. 3.5mm 물리 간격으로 슬라이스를 묶고, 검사당 64 인스턴스, ConvNeXt-S(ImageNet-22k), 소견별 공간 주의를 쓴다. 학습 목표만 소견별 선택 라벨로 바꾸었고, 교사는 쓰지 않았다. 동일 파이프라인을 공개 라벨(blendjev)로 학습한 공개 모델을 대조군으로 사용한다.

## 5. 상보성 기반 앙상블

### 5.1 순위 결합

모델들의 출력 보정 상태가 서로 달라 확률 평균 대신 소견별 백분위 순위의 가중 평균을 사용했다. 모델 집합 $M$, 소견 $c$, 검사 $i$에 대해

$$s_c(i) = \Sigma_{m \in M}\, w_{m,c} \cdot rank_c(p_{m,c}(i)) \,/\, \Sigma_m\, w_{m,c}$$

이며, 여러 단계를 결합할 때는 각 단계의 출력을 다시 순위로 변환한다. AUC는 순위에만 의존하므로 이 결합은 지표와 정합적이다.

### 5.2 소견별 상보성 측정

외부 코호트에서 공개 교사 모델과 우리 전체 시야 모델의 소견별 AUC를 비교하면 강약이 뚜렷이 갈린다(표 3). 외측 골관절염과 슬개대퇴 골관절염에서는 교사 모델이 크게 앞서고, 관절 삼출·반월상연골·베이커 낭종에서는 우리 모델이 앞선다. 모든 소견에 같은 가중치를 주면 약한 소견의 손실이 강한 소견의 이득을 상쇄한다.

| 모델 | 평균 | ACL | 내측 반월 | 외측 반월 | 내측 OA | 외측 OA | PF OA | 삼출 | 활막염 | 베이커 |
|---|---|---|---|---|---|---|---|---|---|---|
| 공개 교사 모델 (CoAtNet) | 0.943 | 0.972 | 0.927 | 0.927 | 0.940 | **0.951** | **0.990** | 0.941 | **0.954** | 0.888 |
| 전체 시야 증류 모델 8개 | 0.943 | 0.977 | **0.937** | **0.944** | 0.956 | 0.880 | 0.965 | 0.957 | 0.950 | **0.917** |
| 교사 없는 공간 주의 모델 2개 | 0.931 | **0.982** | 0.933 | 0.933 | **0.957** | 0.872 | 0.938 | **0.960** | 0.948 | 0.854 |

**표 3.** 외부 코호트(OAI 2,377 무릎)의 소견별 AUC. 공개 교사 모델과 우리 증류 모델 8개는 평균이 같지만(0.9433 대 0.9428) 강한 소견이 서로 다르다.

### 5.3 소견별 가중치

외부 코호트와 G58 양쪽에서 AUC가 증가하는 방향으로 소견별 가중치 $w_c$를 정했다(표 4). 외측·슬개대퇴 골관절염은 0으로 두어 해당 소견을 공개 모델에 맡기고, 우리 모델이 강한 소견에는 15~25%를 할당했다. 교사 없는 공간 주의 모델(4.3절)은 반월상연골·삼출·활막염 네 소견에서만 두 평가 집합 모두 이득이 확인되어 이 소견들에만 10%로 추가했다.

| 소견 | $w_c$ | 소견 | $w_c$ | 소견 | $w_c$ |
|---|---|---|---|---|---|
| ACL | 0.20 | 내측 OA | 0.20 | 활막염 | 0.15 |
| MCL | 0.10 | 외측 OA | 0.00 | 베이커 낭종 | 0.20 |
| 내측 반월상연골 | 0.20 | PF OA | 0.00 | 골좌상 | 0.05 |
| 외측 반월상연골 | 0.15 | 관절 삼출 | 0.25 | 골절 | 0.20 |

**표 4.** 전체 시야 모델 묶음의 소견별 가중치.

### 5.4 최종 구성

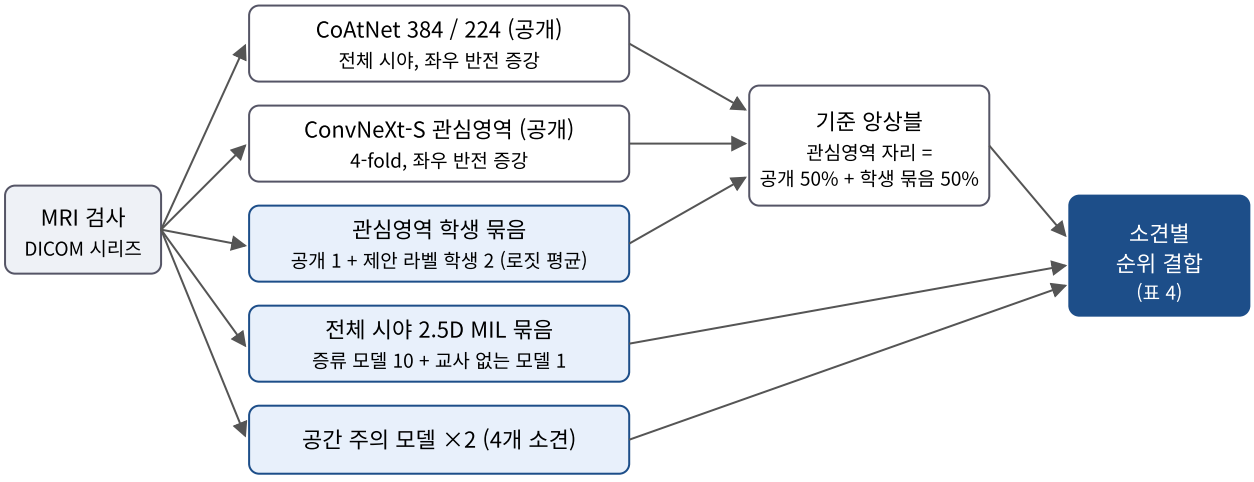



**그림 1.** 최종 앙상블 구조. 파란 상자가 본 연구에서 학습한 모델이다. 기준 앙상블의 두 공개 모델 간 소견별 가중치는 공개된 설정을 따랐다.

## 6. 실험 결과와 분석

### 6.1 단일 모델

| 모델 | 입력 | 목표 | G58 | OAI |
|---|---|---|---|---|
| 2.5D MIL ConvNeXt-T | 전체 시야 | 판독문 라벨 | 0.915~0.921 | – |
| 2.5D MIL ConvNeXt-T | 전체 시야 | 라벨 + 교사 증류 | 0.923~0.931 | 0.939~0.942 |
| 위 8개 앙상블 | 전체 시야 | 라벨 + 교사 증류 | 0.928 | 0.943 |
| ConvNeXt-S 공간 주의 | 전체 시야 | 라벨 (교사 없음) | 0.924 | 0.931 |
| ConvNeXt-S 공간 주의 | 전체 시야 | 소견별 선택 라벨 | 0.913 | 0.923 |
| ConvNeXt-T | 전체 시야 | 소견별 선택 라벨 | 0.923 | 0.936 |
| ConvNeXt-S 관심영역 (공개 라벨) | 관절 중심 | 공개 라벨 | 0.932 | – |
| **ConvNeXt-S 관심영역 (제안)** | 관절 중심 | 소견별 선택 라벨 | **0.941** | – |

**표 5.** 단일 모델 성능(모두 G58을 학습에서 제외). 공개 시험 집합에서 판독문 라벨 단독 모델은 0.941~0.942, 교사 증류 모델은 0.949를 기록했다. 관심영역 모델은 OAI 원본 영상이 없어 외부 코호트에서 평가하지 못했다.

### 6.2 앙상블 구성 요소별 기여

공개된 기준 앙상블(두 공개 모델의 소견별 순위 결합, 공개 시험 AUC 0.958)에서 출발해 구성 요소를 하나씩 더하거나 바꾼 결과를 표 6에 정리했다. 공개 시험 집합은 소수점 셋째 자리까지만 공개되므로, 같은 표시값끼리의 순서는 공개 점수 상위 두 제출을 알려 주는 대회 플랫폼 표시로 판별했다. 이 비교는 순서만 알려 주며 효과 크기를 제공하지 않는다.

| 구성 | 공개 시험 AUC | OAI·G58 근거 |
|---|---|---|
| 기준 앙상블 + 전체 시야 묶음, 모든 소견 균일 10% | 0.957 | – |
| + 소견별 가중치(표 4) | 0.958 | OAI 0.9451 → 0.9474, G58 0.9368 → 0.9382 |
| + 관심영역 공개 모델을 관심영역 자리에 35% | 0.958 (↑) | – |
| + 전체 시야 묶음을 G58 포함 재학습판으로 교체 | 0.958 (↑) | – |
| + 공간 주의 모델, 4개 소견 10% | 0.958 (↑) | 두 집합 모두 해당 소견 이득 |
| + 제안 관심영역 학생(G58 포함), 공개 모델과 로짓 평균 | 0.958 (↑) | G58 0.941 대 0.932 |
| 학생 묶음 비중 35% → 50% | **0.959** | – |
| + 교사 없는 전체 시야 ConvNeXt-T (가중 0.5) | **0.959** (↑) | OAI 앙상블 이득이 8모델 묶음과 동등 |

**표 6.** 구성 요소별 효과. (↑)는 표시값이 같지만 직전 구성보다 높은 순위로 판별된 경우다. 학생 묶음 비중을 65%로 올리거나 공개 관심영역 모델을 우리 재현판으로 대체하면 0.958로 낮아졌다.

### 6.3 지식 증류와 앙상블 기여의 상충

교사 증류는 전체 시야 모델의 공개 시험 AUC를 0.942에서 0.949로 높였다. 그러나 외부 코호트에서 교사 모델에 각 모델을 소견별 최적 가중치로 더했을 때의 AUC 증가량은 단일 성능과 거의 무관했다(표 7). 단일 0.928인 교사 없는 모델과 0.940~0.942인 증류 모델이 모두 +0.008~0.009 범위에 모였고, 증류 모델 8개의 앙상블도 +0.0096에 그쳤다. 증류는 학생의 오차를 교사와 비슷하게 만들어, 단일 성능 향상분이 교사와의 결합에서 대부분 상쇄된다. 이 결과는 같은 입력 표현 안에서 시드, 라벨 혼합 비율, 증류 변형을 늘리는 전략의 한계를 보여 준다. 실제로 2차 교사(공개 두 모델의 결합)로 증류한 학생은 G58 0.920, OAI 0.938로 1차 증류보다 낮지 않았다.

| 교사 모델에 더한 모델 | 단일 OAI AUC | 결합 후 증가량 |
|---|---|---|
| 교사 없는 공간 주의 모델 (단일 시드) | 0.928 | +0.008~0.009 |
| 전체 시야 증류 모델 (각각) | 0.939~0.942 | +0.008~0.009 |
| 전체 시야 증류 모델 8개 앙상블 | 0.943 | +0.0096 |
| 위 8개 + 교사 없는 공간 주의 모델 | – | +0.0099 |

**표 7.** 단일 성능과 앙상블 기여(외부 코호트, 교사 모델 단독 0.9433 기준, 소견별 최적 가중치). 단일 성능이 0.014 차이 나도 결합 이득은 거의 같다.

### 6.4 입력 시야 가설

전체 시야 모델은 외측 골관절염과 슬개대퇴 골관절염에서 일관되게 약했다(OAI 0.880, 0.965). 먼저 좌우 혼동 가설을 검증했다. 왼쪽 무릎을 오른쪽 기준으로 반전해 정규화하고 학습·평가했으며, OAI에서는 실제 좌우 정보를 사용했다. 그래도 외측 골관절염 AUC는 0.874에서 0.871로 변하지 않았다. 입력 해상도를 320px에서 384px로 올려도 차이가 없었다. 반면 같은 ConvNeXt-S 백본과 같은 소견별 선택 라벨로 입력만 관절 중심으로 바꾸자, G58 AUC가 0.913에서 0.941로 크게 향상되었다(표 5).

약 120mm의 전체 시야를 320px로 축소하면 픽셀 간격이 약 0.4mm다. 관심영역 입력은 약 100mm를 288px로 보아 약 0.35mm로, 같은 구조를 더 크게 표현한다. 얇은 연골과 슬개대퇴 관절면을 평가하는 소견일수록 이 차이가 중요하다는 해석과 결과가 일치한다. 또한 이 비교는 같은 G58로 선택한 라벨을 양쪽 모델이 공유하므로, 라벨 선택 편향과 무관한 입력 효과를 보여 준다.

다만 관심영역 모델은 외부 코호트로 평가하지 못해, 외측·슬개대퇴 골관절염에서의 개선을 독립 데이터로 확인하지는 못했다. G58에서 제안 학생은 공개 라벨로 학습된 대조군보다 관절 삼출(0.989 대 0.950, 부트스트랩 2,000회에서 차이 신뢰구간 [+0.006, +0.084])에서 우수했다. 반면 내측 측부인대(0.930 대 0.966, [−0.087, −0.002])에서는 열세였다. 외측 OA(0.845 대 0.851)와 PF OA(0.876 대 0.902)를 포함한 나머지 소견은 신뢰구간이 0을 포함했다. 즉 라벨 교체의 효과는 소견마다 방향이 달랐고, 두 모델을 로짓 평균한 묶음이 어느 한쪽보다 안정적이었다.

### 6.5 부정적 결과

| 방법 | 결과 | 해석 |
|---|---|---|
| 외부 코호트(OAI) 2,377 무릎을 학습에 혼합 (MOAKS 보조 과제 포함) | 공개 시험 0.946~0.947 (기준 0.949) | 도메인 차이가 이득을 상회 |
| 교사 대신 자체 교차검증 예측으로 의사 라벨 | 0.945~0.946 | 약한 교사로 대체한 효과 |
| 2차 증류 (공개 두 모델 결합 교사) | G58 0.920, OAI 0.938 | 교사 결합의 오차 구조를 학습해 다양성 감소 |
| 좌우 정규화, 384px 해상도 | 변화 없음 | 병목은 시야 |
| 작은 배치(2)와 큰 헤드 학습률(1e-3)의 전체 시야 모델 | 학습 발산 | 최적화 불안정 |
| 여러 소견에 보조 모델을 G58 기준으로 세밀하게 선택·가중 | 개선 없음 | 58건 기준 선택의 과적합 |

**표 8.** 효과가 없었거나 성능을 낮춘 시도.

## 7. 논의

**상보성 측정의 가치.** 공개 모델보다 단일 성능이 낮은 모델도, 그 모델이 강한 소견을 정확히 식별하면 앙상블에 기여할 수 있었다. 이 판단에는 학습 데이터와 독립된 외부 코호트가 결정적이었다. 학습 데이터에 대한 교사

예측은 표본 내 예측이라 편향되어 있고, G58은 너무 작기 때문이다.

**라벨과 표현의 분리.** 소견별 선택 라벨은 전체 시야 모델에서는 이득이 불분명했다. 그러나 관심영역 모델에서는 공개 라벨 대조군보다 높은 성능으로 이어졌다. 라벨 품질의 향상은 입력 표현이 해당 소견을 판별할 수 있을 때에만 드러난다는 해석이 가능하다.

**계산 제약.** 추론은 GPU 두 장으로 9시간 안에 끝나야 했다. 관심영역 모델 세 개를 포함한 구성은 이 한계에 근접했다. 전체 시야 모델들의 렌더링을 한 번으로 통합하고 두 GPU에 표본을 분할해, 출력이 동일한 상태로 실행 시간을 줄였다. 다만 모델을 더 늘리면 여유가 다시 사라졌다. 실행 시간은 정확도와 함께 설계 변수로 다뤄야 한다.

## 8. 한계

- G58은 라벨 출처 선택, 앙상블 가중치 결정, 모델 비교에 겹쳐 사용되었다. 따라서 G58 수치에는 선택 편향이 있으며 탐색적 지표로만 해석해야 한다.
- 외부 코호트는 9개 소견만 포함하고, 연령대·장비·촬영 프로토콜이 대회 데이터와 다르다. 관심영역 모델은 원본 영상이 없어 외부 코호트로 평가하지 못했다.
- 공개 시험 집합의 결과는 소수점 셋째 자리까지만 관찰되었다. 같은 표시값 안의 비교는 순서 정보뿐이며, 숨겨진 나머지 70%에서의 효과를 보장하지 않는다.
- 사용한 공개 모델 중 일부는 학습에 외부 데이터(OAI, fastMRI, SKM-TEA)를 사용했다.

## 9. 결론

판독문만 주어지는 대규모 무릎 MRI 데이터에서, 다중모달 대규모 언어모델 라벨과 소견별 출처 선택은 라벨 품질을 높였다. 독립 외부 코호트로 측정한 소견별 상보성에 기반해 가중치를 두는 앙상블은 균일 결합보다 일관되게 나았다. 지식 증류는 단일 성능을 높이지만 교사와의 결합 이득을 줄였다. 이후의 성능 향상은 증류 변형이 아니라 입력 표현의 변화, 곧 관절 중심 관심영역 학습에서 나왔다. 최종 앙상블은 숨겨진 시험 데이터의 공개 부분에서 AUC 0.959를 기록했다.

## 감사의 말

본 연구는 공개된 모델과 코드를 기반으로 수행되었다. CoAtNet 기반 MIL 레시피(dreaddevelopment), CoAtNet 가중치와 관심영역 모델 학습 코드·라벨(nartaa), 관심영역 ConvNeXt 모델과 해부학 기준점 코드(heliosli), 2.5D ConvNeXt 판독기(goodpjw2008), 판독문 라벨(riadmohamed42, stevenleehans, pilkwang)의 저자들에게 감사한다. OAI 데이터는 NIMH Data Archive를 통해 이용했으며(Dataset identifier 10.15154/0hcg-f676), 본 보고서에는 집계 지표만 포함했다.

## 부록 A. 구현 세부

| 항목 | 설정 |
|---|---|
| 전체 시야 모델 | ConvNeXt-T(ImageNet-12k), 384px 캐시에서 320px 입력, 검사당 16 인스턴스, 배치 8, AdamW(백본 1e-4, 헤드 5e-4), 15 epoch, EMA 0.999 |
| 관심영역 학생 | ConvNeXt-S(ImageNet-22k), 288px 크롭(320px 캐시), 3.5mm 슬라이스 간격, 검사당 64 인스턴스, 배치 2, 백본 1e-4·헤드 1e-3, 16 epoch, 소견별 정규화 BCE, 출력 편향을 사전 확률 로짓으로 초기화 |
| 학습 장비 | 단일 RTX 5060 Ti 16GB (전체 시야 모델 1.7~2.7시간, 관심영역 학생 약 16시간) |
| 추론 환경 | T4 GPU 2장, 인터넷 차단, 9시간 제한 |
| 최종 학습 데이터 | 최종 모델은 G58을 포함해 재학습(전체 시야 모델은 2배 가중) |